

BÁO CÁO ĐỒ ÁN CUỐI KỲ

Học phần: IT2039 – Chuyên đề Xử Lý Tín Hiệu Hình Ảnh Y Khoa

MÔ HÌNH ĐA PHƯƠNG THỨC PHÂN TẦNG NGUY CƠ XƠ VỮA ĐỘNG MẠCH CẢNH

Multimodal Deep Learning for Carotid Atherosclerosis Risk Stratification

Giảng viên hướng dẫn: Nguyễn Tất Bảo Thiện

Sinh viên thực hiện: Nguyễn Hoàng Nam – MSHV: 250201018
Vũ Đức Mạnh – MSHV: 250201075

LỜI CẢM ƠN

Chúng em xin gửi lời cảm ơn chân thành đến thầy Nguyễn Tất Bảo Thiện, giảng viên học phần IT2039 – Chuyên đề Xử Lý Tín Hiệu Hình Ảnh Y Khoa, đã tận tình giảng dạy, cung cấp nền tảng kiến thức về xử lý ảnh y khoa và định hướng phương pháp luận nghiên cứu trong suốt học phần.

Đồ án này được xây dựng dựa trên nền tảng của hướng dẫn lâm sàng *2025 Focused Update of the 2019 ESC/EAS Guidelines for the management of dyslipidaemias* (Mach và cộng sự, 2025), cùng nhiều công trình nghiên cứu liên quan về ứng dụng học sâu trong chẩn đoán xơ vữa động mạch cảnh. Chúng em xin ghi nhận đóng góp học thuật của các tác giả gốc.

Do giới hạn về thời gian, tài nguyên tính toán (GPU) và bản chất tổng hợp (synthetic) của bộ dữ liệu ảnh sử dụng trong đồ án, một số kết quả thực nghiệm còn tồn tại hạn chế đã được chúng em trình bày trung thực và phân tích chi tiết trong Chương 5. Mọi thiếu sót trong báo cáo là trách nhiệm của nhóm thực hiện.

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày tháng năm 2026

Giảng viên hướng dẫn

Nguyễn Tất Bảo Thiện

BẢNG PHÂN CÔNG, ĐÁNH GIÁ THÀNH VIÊN

Thành viên	Công việc phụ trách	Mức độ hoàn thành	Đánh giá
Nguyễn Hoàng Nam (250201018)	EDA & xử lý dữ liệu (Phase 1–2); Baseline tabular & CNN-only (Phase 3); Huấn luyện Fusion model, ablation study (Phase 4–7); Viết báo cáo	100%	10/10
Vũ Đức Mạnh (250201075)	Thiết kế kiến trúc multimodal fusion (Image Branch, Tabular Branch, Fusion Layer, Cross-Attention); Phân tích discordance subgroup; Rà soát và kiểm định kết quả; Chỉnh sửa báo cáo	100%	10/10

Mục lục

LỜI CẢM ƠN	1
NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN	2
BẢNG PHÂN CÔNG, ĐÁNH GIÁ THÀNH VIÊN	3
TÓM TẮT ĐỒ ÁN	8
1 TỔNG QUAN BÀI TOÁN	9
1.1 Đặt vấn đề lâm sàng	9
1.2 Ý nghĩa khoa học của tài liệu tham chiếu gốc	10
1.3 Mục tiêu và phạm vi đồ án	10
1.4 Động lực chọn đề tài và tiềm năng phát triển	11
1.4.1 Động lực chọn đề tài	11
1.4.2 Tiềm năng của đề tài	11
2 CÁC CÔNG VIỆC LIÊN QUAN	13
2.1 Hướng dẫn lâm sàng ESC/EAS 2025	13
2.2 Học máy trên dữ liệu lâm sàng dạng bảng cho dự đoán nguy cơ tim mạch	13
2.3 Học sâu trên ảnh siêu âm động mạch cảnh	13
2.4 Kỹ thuật multimodal fusion và phân loại kết hợp phân đoạn	14
2.5 Cơ chế Cross-Attention trong multimodal fusion	14
2.6 Tổng hợp khoảng trống nghiên cứu (research gap)	14
3 PHƯƠNG PHÁP LUẬN	15
3.1 Tổng quan quy trình thực hiện (Pipeline)	15
3.2 Mô tả dữ liệu	15
3.2.1 Nguồn dữ liệu và cỡ mẫu	15
3.2.2 Nhãn đa nhiệm (multi-task labels)	16
3.2.3 Định nghĩa nhóm Discordant	16
3.3 Kiến trúc mô hình Multimodal Fusion	16
3.3.1 Tổng quan kiến trúc	16
3.3.2 Image Branch	17
3.3.3 Tabular Branch	18
3.3.4 Fusion Layer – so sánh 2 cơ chế	18
3.3.5 Output Heads đa nhiệm	18
3.4 Các mô hình Baseline	18
3.5 Chiến lược huấn luyện và đánh giá	19
3.5.1 Cấu hình huấn luyện	19

3.5.2	Chiến lược cross-validation	19
3.5.3	Bộ chỉ số đánh giá	19
3.6	Thiết kế Ablation Study	20
3.7	Môi trường thực nghiệm	20
4	THỰC NGHIỆM VÀ KẾT QUẢ	21
4.1	Khảo sát dữ liệu (EDA)	21
4.1.1	Phân bố Lp(a) theo guideline ESC/EAS 2025	21
4.1.2	Phân bố nhân và mất cân bằng lớp	22
4.1.3	Phân bố nhóm Discordant	22
4.2	Kết quả 5 mô hình Baseline	23
4.2.1	Feature Importance	24
4.3	Kết quả mô hình Fusion	24
4.4	Ablation Study	25
4.5	Phân tích Subgroup Discordant – Trọng tâm khoa học của đồ án	25
4.5.1	Khả năng phát hiện đúng (Recall) trên 26 ca discordant có mảng bám thật	26
4.5.2	Phát hiện quan trọng: phân tích False Positive trên nhóm “Lp(a)-only”	26
4.6	Head 2 – Đánh giá phân loại Echogenicity (RQ2)	27
4.7	Trả lời 4 Research Questions	28
5	THẢO LUẬN VÀ HẠN CHẾ	29
5.1	Vấn đề: AUC gần tuyệt đối của nhánh ảnh – điều tra nguyên nhân	29
5.1.1	Hiện tượng quan sát được	29
5.1.2	Quy trình điều tra	29
5.1.3	Kết luận về nguyên nhân	30
5.2	Vấn đề kỹ thuật đã phát hiện và khắc phục: lỗi round-trip CSV	30
5.3	Vấn đề hiệu chuẩn: bất ổn định ngưỡng quyết định của CNN-only	30
5.4	Hiệu ứng trần (Ceiling Effect) trong Ablation Study	31
5.5	So sánh với công trình liên quan – khoảng cách đến khả năng triển khai lâm sàng	31
5.6	Tóm tắt các hạn chế chính	31
6	HƯỚNG PHÁT TRIỂN TIẾP THEO	32
6.1	Kiểm chứng lại trên dữ liệu ảnh siêu âm thật	32
6.2	Hiệu chuẩn ngưỡng quyết định (Threshold Calibration)	32
6.3	Thiết kế lại Ablation Study	32
6.4	Mở rộng cỡ mẫu và kiểm định thống kê trên Subgroup Discordant	32
6.5	Tích hợp Explainable AI (XAI)	33
6.6	Học liên tục đa trung tâm (Multi-center Validation)	33
7	KẾT LUẬN	34
7.1	Tóm tắt đóng góp	34
7.2	Ý nghĩa thực tiễn	34
7.3	Nhận định cuối cùng	34
	TÀI LIỆU THAM KHẢO	36

Danh sách hình vẽ

3.1	Kiến trúc mô hình Multimodal Fusion	17
4.1	Tỷ lệ mảng bám theo Lp(a) tier	21
4.2	Phân bố nhân Plaque_present	22
4.3	Phân bố 4 lớp Plaque_echogenicity	22
4.4	Phân nhóm bệnh nhân theo tiêu chí ESC/EAS 2025	22
4.5	So sánh AUC và Sens@discordant giữa các baseline	23
4.6	Feature importance của Random Forest và XGBoost	24
4.7	So sánh AUC-ROC và Sensitivity trên nhóm discordant	25
4.8	Recall trên các ca discordant có mảng bám thật	26
4.9	Confusion matrix Head 2 (Echogenicity)	27

Danh sách bảng

1.1	Phân bố các nhóm discordant theo định nghĩa ESC/EAS 2025	12
3.1	Tổng quan pipeline thực nghiệm	15
3.2	Các mô hình baseline	19
3.3	Siêu tham số huấn luyện Fusion model	19
3.4	5 biến thể Ablation Study	20
4.1	Tỷ lệ có mảng bám theo mức phân tầng Lp(a)	21
4.2	Hiệu năng 5 mô hình baseline	23
4.3	So sánh toàn diện 7 mô hình	24
4.4	Kết quả Ablation Study	25
4.5	Số ca discordant có mảng bám thật được phát hiện đúng	26
4.6	Báo động giả trên nhóm discordant Lp(a)-only	27
4.7	Tổng hợp trả lời 4 Research Questions	28
5.1	Tính bất ổn định của ngưỡng quyết định CNN-only	30

TÓM TẮT ĐỒ ÁN

Xơ vữa động mạch cảnh là nguyên nhân hàng đầu dẫn đến đột quỵ do thiếu máu não, nhưng việc đánh giá nguy cơ hiện nay vẫn chủ yếu dựa trên bộ chỉ số lipid máu (LDL-C) theo hướng dẫn ESC/EAS. Vấn đề đặt ra là tồn tại một nhóm bệnh nhân “*discordant*” – có chỉ số LDL-C đạt mục tiêu điều trị (an toàn trên giấy tờ) nhưng thực tế lại có mảng bám động mạch hoặc chỉ số Lipoprotein(a) [Lp(a)] tăng cao, khiến nguy cơ tim mạch thật sự bị đánh giá thấp hơn thực tế.

Đồ án này xây dựng và đánh giá một mô hình học sâu đa phương thức (multimodal deep learning), kết hợp hai nguồn thông tin bổ trợ nhau: (1) **Image Branch** sử dụng ResNet-50 trích xuất đặc trưng từ ảnh siêu âm cắt ngang động mạch cảnh để phát hiện mảng bám và phân loại độ hồi âm (echogenicity); (2) **Tabular Branch** sử dụng mạng MLP 3 lớp mã hoá 9 chỉ số sinh hoá lâm sàng (Lp(a), ApoB, LDL-C, IMT...) để đánh giá nguy cơ theo chuẩn ESC/EAS 2025. Hai nhánh được hợp nhất (fusion) qua hai cơ chế được so sánh trực tiếp – Concatenation và Cross-Attention – rồi đưa vào 3 đầu ra dự đoán đa nhiệm (multi-task): phát hiện mảng bám, phân loại echogenicity 4 lớp, và dự đoán nhu cầu tái phân tầng nguy cơ.

Trên bộ dữ liệu 300 bệnh nhân (205 control / 95 case) với 33 trường hợp “discordant” theo đúng định nghĩa của guideline ESC/EAS 2025, mô hình Fusion đạt AUC-ROC ≈ 0.9996 (Concat) và bắt được toàn bộ 26/26 trường hợp discordant có mảng bám thật – vượt trội so với quy tắc lâm sàng truyền thống (ESC/EAS Rule, AUC = 0.523, chỉ bắt được 4/26 trường hợp). Đáng chú ý, phân tích ở cấp độ từng ca bệnh cho thấy giá trị gia tăng thực sự của Fusion không nằm ở độ nhạy (CNN-only đơn nhánh cũng đạt độ nhạy tuyệt đối) mà ở **độ đặc hiệu**: Fusion Concat không báo động giả trên bất kỳ trường hợp nào trong nhóm 7 bệnh nhân “Lp(a) cao nhưng không có mảng bám thật”, trong khi CNN-only đơn nhánh báo động giả tới 6/7 trường hợp.

Báo cáo cũng trình bày trung thực các hạn chế phát hiện được trong quá trình thực nghiệm: (i) bản chất ảnh siêu âm tổng hợp (synthetic) với đặc trưng hình học đơn giản khiến nhánh ảnh đơn lẻ đã đạt AUC gần tuyệt đối, làm giảm giá trị minh chứng của kiến trúc đa phương thức; (ii) hiện tượng “ceiling effect” khiến ablation study không thể đánh giá đúng đóng góp của Lp(a)/ApoB; (iii) vấn đề hiệu chuẩn ngưỡng (calibration) không ổn định của nhánh CNN. Những phân tích phản biện này được xem là đóng góp quan trọng của đồ án, bên cạnh kết quả định lượng.

Từ khóa: xơ vữa động mạch cảnh, học sâu đa phương thức, ResNet-50, multimodal fusion, cross-attention, ESC/EAS 2025, Lipoprotein(a), phân tầng nguy cơ tim mạch.

Chương 1

TỔNG QUAN BÀI TOÁN

1.1 Đặt vấn đề lâm sàng

Đột quỵ do thiếu máu não cục bộ (ischemic stroke) là một trong những nguyên nhân gây tử vong và tàn phế hàng đầu trên toàn cầu, và xơ vữa động mạch cảnh (carotid atherosclerosis) được xác định là một cơ chế bệnh sinh trực tiếp: mảng bám hình thành và phát triển trong lòng động mạch cảnh có thể vỡ ra, gây tắc mạch não. Vì vậy, việc phát hiện sớm và phân tầng đúng nguy cơ hình thành mảng bám có ý nghĩa sống còn trong dự phòng đột quỵ.

Theo thực hành lâm sàng hiện tại, việc đánh giá nguy cơ tim mạch chủ yếu dựa trên bộ chỉ số lipid máu truyền thống, đặc biệt là nồng độ Cholesterol tỷ trọng thấp (LDL-C). Hướng dẫn lâm sàng mới nhất – 2025 *Focused Update of the 2019 ESC/EAS Guidelines for the management of dyslipidaemias* (Mach và cộng sự, 2025) – tiếp tục khẳng định LDL-C là mục tiêu điều trị trung tâm, đồng thời nhấn mạnh vai trò ngày càng quan trọng của **Lipoprotein(a) [Lp(a)]** như một yếu tố nguy cơ độc lập, ít phụ thuộc vào lối sống và khó điều chỉnh bằng thuốc hạ lipid thông thường.

Nghịch lý “Discordance”

Vấn đề cốt lõi mà đồ án tập trung giải quyết là hiện tượng **discordance** (bất tương hợp): tồn tại một nhóm bệnh nhân có chỉ số LDL-C đã đạt mục tiêu điều trị theo phân tầng nguy cơ (an toàn “trên giấy tờ”), nhưng trên thực tế lại có ít nhất một trong hai yếu tố sau:

- Lp(a) tăng cao (> 50 mg/dL theo ngưỡng Box 1 của guideline ESC/EAS 2025)
- Đã có mảng bám (plaque) hình thành thực sự trên hình ảnh siêu âm động mạch cảnh

nhưng những yếu tố này không được phản ánh đầy đủ nếu chỉ dựa vào chỉ số LDL-C đơn thuần. Nhóm bệnh nhân discordant vì vậy có nguy cơ bị **đánh giá thấp hơn thực tế** (under-classified), dẫn đến bỏ lỡ cơ hội can thiệp dự phòng sớm.

Trên bộ dữ liệu 300 bệnh nhân sử dụng trong đồ án, quá trình khảo sát dữ liệu (Chương 4) xác định được đúng **33/300 (11,0%)** trường hợp discordant theo định nghĩa chính thức của guideline (Box 1, Table 3–4), chia thành các nhóm nhỏ (Bảng 1.1).

Hạn chế của phương pháp đánh giá truyền thống

Cách tiếp cận truyền thống – áp dụng trực tiếp công thức/lượng (rule-based) từ guideline lên chỉ số lipid máu – có ưu điểm là đơn giản, minh bạch, dễ triển khai tại tuyến y tế cơ sở. Tuy nhiên, phương pháp này có 2 hạn chế cơ bản khi đối diện với nhóm discordant:

1. **Không tận dụng thông tin hình ảnh:** hướng dẫn ESC/EAS 2025 công nhận vai trò của hình ảnh động mạch cảnh (mảng bám, độ dày lớp nội trung mạc – IMT) trong tái phân tầng nguy cơ, nhưng việc đọc và diễn giải ảnh siêu âm phụ thuộc nhiều vào kinh nghiệm bác sĩ, tốn thời gian, và có tính chủ quan.
2. **Ngưỡng cứng (hard threshold):** luật lâm sàng dựa trên ngưỡng cố định (ví dụ $Lp(a) > 50$ mg/dL) không nắm bắt được các tương tác phi tuyến giữa nhiều biến số sinh hoá và hình ảnh cùng lúc – điều mà mô hình học máy/học sâu có tiềm năng khai thác tốt hơn.

Đây chính là động lực để đề án đề xuất một mô hình học sâu đa phương thức (multimodal deep learning), kết hợp đồng thời thông tin hình ảnh siêu âm và dữ liệu lâm sàng dạng bảng, nhằm hỗ trợ phát hiện và tái phân tầng đúng nhóm bệnh nhân discordant – nhóm mà phương pháp truyền thống dễ bỏ sót nhất.

1.2 Ý nghĩa khoa học của tài liệu tham chiếu gốc

Đề án lấy 2025 *Focused Update of the 2019 ESC/EAS Guidelines for the management of dyslipidaemias* (Mach và cộng sự, 2025, European Heart Journal, ehaf190) làm tài liệu tham chiếu lâm sàng nền tảng. Đây là bản cập nhật chính thức, được xây dựng bởi lực lượng chuyên trách chung của Hiệp hội Tim mạch Châu Âu (ESC) và Hiệp hội Xơ vữa động mạch Châu Âu (EAS), có ý nghĩa:

- Xác lập lại vai trò trung tâm của LDL-C trong điều trị rối loạn lipid máu, đồng thời đưa $Lp(a)$ trở thành yếu tố cần được đo lường và cân nhắc một cách hệ thống hơn so với các phiên bản guideline trước.
- Cung cấp bộ ngưỡng LDL-C mục tiêu phân theo 4 mức nguy cơ (Low/Moderate/High/Very High) – được đề án sử dụng trực tiếp làm cơ sở cho baseline luật lâm sàng (ESC/EAS Rule, Chương 3).
- Đưa ra định nghĩa và tiêu chí về “risk modifier” và nhu cầu tái phân tầng (reclassification) khi có bằng chứng hình ảnh về mảng bám – là cơ sở lâm sàng cho việc xây dựng nhãn “discordant” và đầu ra Head 3 (Reclassify) của mô hình multimodal trong đề án.

Việc “số hoá” và tự động hoá một phần quy trình đánh giá theo guideline này bằng học sâu – đặc biệt là khai thác đồng thời cả kênh hình ảnh lẫn kênh chỉ số sinh hoá – là hướng tiếp cận có giá trị thực tiễn, phù hợp với xu thế AI hỗ trợ chẩn đoán (AI-assisted diagnosis) đang phát triển mạnh trong tim mạch học hiện đại.

1.3 Mục tiêu và phạm vi đề án

Mục tiêu

1. Xây dựng mô hình học sâu đa phương thức (multimodal fusion) kết hợp ảnh siêu âm động mạch cảnh (Image Branch – ResNet-50) và 9 chỉ số lâm sàng (Tabular Branch – MLP), giải quyết đồng thời 3 bài toán: phát hiện mảng bám, phân loại độ hồi âm (echogenicity), và dự đoán nhu cầu tái phân tầng nguy cơ theo ESC/EAS 2025.
2. So sánh định lượng hiệu năng của mô hình Fusion với 5 baseline: luật lâm sàng (ESC/EAS Rule), 3 mô hình học máy cổ điển trên dữ liệu bảng (Random Forest, XGBoost, MLP), và mô hình học sâu chỉ dùng ảnh (CNN-only).
3. Đánh giá đóng góp riêng của từng thành phần kiến trúc (ablation study) và so sánh 2 cơ chế fusion (Concatenation và Cross-Attention).
4. Phân tích chuyên sâu hiệu năng mô hình trên đúng nhóm bệnh nhân discordant – phép thử quan trọng nhất cho giá trị lâm sàng thực sự của cách tiếp cận đa phương thức.

Phạm vi thực nghiệm

- **Dữ liệu:** 300 hồ sơ bệnh nhân (205 control không có mảng bám / 95 case có mảng bám), mỗi hồ sơ gồm 9 biến lâm sàng dạng bảng và ảnh siêu âm cắt ngang động mạch cảnh (1 ảnh IMT cho control; 5 ảnh – 1 IMT + 4 mặt cắt ngang động mạch cảnh chung trái/phải – cho case).
- **Nhân dự đoán (multi-task):** (1) Plaque_present – nhị phân; (2) Plaque_echogenicity – 4 lớp (None/Low/Intermediate/High); (3) needs_reclassify – nhị phân, theo định nghĩa ESC/EAS 2025.
- **Chiến lược đánh giá:** Stratified 5-fold cross-validation cho các baseline tabular và CNN-only; đánh giá riêng biệt (subgroup analysis) trên 33 trường hợp discordant.
- **Giới hạn phạm vi:** đồ án không thực hiện thu thập dữ liệu lâm sàng mới, mà sử dụng bộ dữ liệu đã được chuẩn bị sẵn (bao gồm thành phần ảnh tổng hợp – synthetic); không triển khai hệ thống trên môi trường lâm sàng thực tế. Các hạn chế phát sinh từ đặc điểm này được phân tích chi tiết ở Chương 5.

1.4 Động lực chọn đề tài và tiềm năng phát triển

1.4.1 Động lực chọn đề tài

Nhóm thực hiện lựa chọn đề tài này xuất phát từ ba động lực chính:

- **Tính thời sự của Lp(a) trong tim mạch học:** Lp(a) mới chỉ được đưa vào các khuyến cáo lâm sàng chính thức như một yếu tố nguy cơ cần đo lường hệ thống trong những năm gần đây (được củng cố rõ nét trong ESC/EAS 2025). Đây là cơ hội để tiếp cận và ứng dụng một hướng nghiên cứu còn tương đối mới trong lĩnh vực AI y khoa.
- **Bài toán multimodal fusion mang tính đại diện cao:** kết hợp ảnh y khoa và dữ liệu lâm sàng dạng bảng là một trong những hướng nghiên cứu trọng tâm của xử lý tín hiệu hình ảnh y khoa hiện đại, đòi hỏi giải quyết đồng thời các vấn đề về kiến trúc mạng (CNN, MLP, cơ chế fusion), học đa nhiệm (multi-task learning), và mất cân bằng lớp (class imbalance).
- **Giá trị của tư duy phản biện trong nghiên cứu:** quá trình thực nghiệm của đồ án phát sinh nhiều vấn đề thực tế (data pipeline bug, nghi vấn “kết quả quá tốt để là thật”...) đòi hỏi nhóm phải chủ động kiểm chứng, truy vết nguyên nhân bằng việc đọc mã nguồn và trực quan hoá dữ liệu – đây là kỹ năng cốt lõi của một kỹ sư AI, không kém phần quan trọng so với việc đạt điểm số cao.

1.4.2 Tiềm năng của đề tài

Nếu được phát triển tiếp trên dữ liệu siêu âm lâm sàng thực tế (thay vì dữ liệu tổng hợp), hướng tiếp cận multimodal fusion trong đồ án có tiềm năng ứng dụng thực tiễn ở các khía cạnh:

- Hỗ trợ bác sĩ tầm soát tim mạch tại các cơ sở y tế không có chuyên gia đọc siêu âm mạch máu giàu kinh nghiệm, thông qua một công cụ hỗ trợ quyết định (decision support) kết hợp cả chỉ số xét nghiệm lẫn hình ảnh.
- Giảm tỷ lệ bỏ sót các trường hợp nguy cơ cao bị “che giấu” bởi chỉ số LDL-C bình thường (nhóm discordant) – nhóm có ý nghĩa lâm sàng đặc biệt quan trọng vì dễ bị đánh giá thấp nguy cơ nếu chỉ dựa vào xét nghiệm máu.
- Mở rộng sang các bài toán multimodal khác trong tim mạch học và các chuyên khoa hình ảnh y khoa nói chung, nơi việc kết hợp dữ liệu cấu trúc (structured) và phi cấu trúc (ảnh) đang là xu hướng chủ đạo.

Bảng 1.1: Phân bố các nhóm discordant theo định nghĩa ESC/EAS 2025 (n = 300)

Nhóm phân loại	Số bệnh nhân (n)	Tỷ lệ (%)
Above LDL goal (chưa đạt mục tiêu LDL-C)	210	70,00
Truly low risk (nguy cơ thấp thực sự)	57	19,00
Discordant: plaque only	22	7,33
Discordant: Lp(a) only	7	2,33
Discordant: both (Lp(a) & plaque)	4	1,33
Tổng discordant	33	11,00

Chương 2

CÁC CÔNG VIỆC LIÊN QUAN

Chương này điểm qua các công trình nền tảng mà đồ án kế thừa hoặc dùng làm điểm đối chiếu, gồm: (1) hướng dẫn lâm sàng ESC/EAS 2025; (2) các nghiên cứu ứng dụng học máy/học sâu trên dữ liệu lâm sàng dạng bảng để dự đoán nguy cơ tim mạch; (3) các nghiên cứu học sâu trên ảnh siêu âm động mạch cảnh; và (4) các kỹ thuật nền tảng về kiến trúc multimodal fusion.

2.1 Hướng dẫn lâm sàng ESC/EAS 2025

Mach và cộng sự (2025) công bố bản cập nhật 2025 *Focused Update of the 2019 ESC/EAS Guidelines for the management of dyslipidaemias* trên European Heart Journal – tài liệu tham chiếu lâm sàng trung tâm của đồ án. Bên cạnh việc củng cố vai trò của LDL-C, điểm mới quan trọng nhất của bản cập nhật này là đưa Lp(a) vào diện cần được đo lường một lần trong đời đối với mỗi cá nhân trưởng thành, và định nghĩa rõ ngưỡng nguy cơ (Lp(a) > 50 mg/dL) như một “risk-enhancing factor” độc lập với LDL-C. Đồ án khai thác trực tiếp: (i) bảng ngưỡng mục tiêu LDL-C theo 4 mức nguy cơ (Bảng 4 của guideline) để xây dựng baseline luật lâm sàng; (ii) tiêu chí risk modifier/tái phân tầng để xây dựng định nghĩa nhân discordant và đầu ra Head 3 của mô hình.

2.2 Học máy trên dữ liệu lâm sàng dạng bảng cho dự đoán nguy cơ tim mạch

Vu và cộng sự (2025)¹ thực hiện một nghiên cứu quy mô lớn (7 260 người tham gia, theo dõi trung bình 15 năm) để dự đoán nguy cơ bệnh mạch vành (CHD) từ 28 biến số lâm sàng, so sánh 5 mô hình học máy (Logistic Regression, Random Forest, SVM, XGBoost, LightGBM) và sử dụng SHAP để diễn giải đóng góp của từng yếu tố nguy cơ. Random Forest đạt hiệu năng cao nhất (AUC $\approx$ 0,73). Nghiên cứu này định hình cách tiếp cận **Tabular Branch** của đồ án: (i) lựa chọn bộ 3 mô hình baseline tabular tương tự (Random Forest, XGBoost, MLP thay cho SVM/LightGBM để đồng bộ với kiến trúc neural network của Fusion model); (ii) áp dụng phương pháp đánh giá đa chỉ số (AUC, sensitivity, specificity, F1) và phân tích feature importance tương tự cách Vu và cộng sự dùng SHAP để diễn giải mô hình.

2.3 Học sâu trên ảnh siêu âm động mạch cảnh

Hai công trình sau đóng vai trò định hình trực tiếp thiết kế **Image Branch** và bài toán phân loại echogenicity của đồ án:

¹Vu T, Kokubo Y, Inoue M, et al. Machine Learning Model for Predicting Coronary Heart Disease Risk: Development and Validation Using Insights From a Japanese Population-Based Study. *JMIR Cardio*, 2025;9:e68066.

He và cộng sự (2024)² xây dựng thuật toán học sâu (BCNN-ResNet – kết hợp Bilinear CNN với ResNet) trên 3 860 ảnh siêu âm từ 1 339 bệnh nhân để phát hiện mảng bám và đánh giá độ ổn định (stability) của mảng bám, kiểm định trên cả tập nội bộ lẫn tập ngoại kiểm (external test) từ một bệnh viện khác. Việc BCNN-ResNet đạt hiệu năng tốt và ổn định trên tập ngoại kiểm minh chứng tính khả thi của kiến trúc dựa trên ResNet cho bài toán phát hiện mảng bám – củng cố lựa chọn ResNet-50 pretrained làm backbone cho Image Branch của đồ án.

Gao và cộng sự (2026)³ đề xuất một mô hình học sâu hướng tới khả năng triển khai lâm sàng thực tế (clinically deployable) cho bài toán phân tầng nguy cơ đột quỵ dựa trên đặc điểm mảng bám xơ vữa động mạch cảnh, nhấn mạnh yêu cầu về tính ổn định, khả năng diễn giải, và hiệu năng nhất quán khi đưa vào quy trình khám sàng lọc thực tế. Nghiên cứu này là tài liệu tham chiếu quan trọng cho phần Thảo luận (Chương 5) của đồ án, khi đối chiếu khoảng cách giữa một mô hình đạt chỉ số cao trên tập dữ liệu thực nghiệm (như Fusion model của đồ án) với yêu cầu “deployability” trong môi trường lâm sàng thật.

2.4 Kỹ thuật multimodal fusion và phân loại kết hợp phân đoạn

Ren và cộng sự (2026)⁴ đề xuất một framework tầng (cascaded) kết hợp bộ phân loại dựa trên ResNet (Masked-ResNet-DS) với MedSAM (biến thể y khoa của Segment Anything Model) để giải quyết đồng thời 2 bài toán phân loại và phân đoạn mảng bám, chia sẻ thông tin vị trí mảng bám giữa 2 nhánh nhiệm vụ thông qua class activation map (CAM). Cách tiếp cận đa nhiệm (multi-task), nơi các nhánh nhiệm vụ chia sẻ và tăng cường lẫn nhau, là nguồn cảm hứng trực tiếp cho thiết kế **3 output heads** (Plaque Detection, Echogenicity, Reclassify) chia sẻ chung một joint embedding trong kiến trúc Fusion model của đồ án (Chương 3).

2.5 Cơ chế Cross-Attention trong multimodal fusion

Bên cạnh phương pháp fusion đơn giản bằng phép nối (concatenation) đặc trưng của các nhánh, cơ chế *Cross-Attention* – vốn bắt nguồn từ kiến trúc Transformer – ngày càng được sử dụng phổ biến trong các mô hình multimodal, cho phép một phương thức (ví dụ ảnh) đóng vai trò Query để “truy vấn” thông tin liên quan từ phương thức còn lại (ví dụ dữ liệu lâm sàng) đóng vai trò Key/Value, thay vì đơn thuần ghép nối đặc trưng theo cách tĩnh. Đồ án triển khai và so sánh trực tiếp thực nghiệm giữa Concatenation Fusion và Cross-Attention Fusion (Chương 3–4), nhằm trả lời câu hỏi nghiên cứu RQ4: liệu cơ chế attention có mang lại lợi ích thực chất so với phương pháp ghép nối đơn giản hơn trên bài toán và quy mô dữ liệu cụ thể của đồ án hay không.

2.6 Tổng hợp khoảng trống nghiên cứu (research gap)

Từ các công trình trên, có thể thấy phần lớn nghiên cứu hiện có tập trung **đơn phương thức**: hoặc thuần tabular (Vu và cộng sự, 2025), hoặc thuần ảnh (He và cộng sự, 2024; Gao và cộng sự, 2026; Ren và cộng sự, 2026). Rất ít nghiên cứu kết hợp đồng thời cả hai nguồn thông tin và đánh giá riêng biệt hiệu năng trên đúng nhóm bệnh nhân mà một phương thức đơn lẻ (chỉ lipid, hoặc chỉ ảnh) có khả năng đánh giá sai – tức nhóm discordant. Đây chính là khoảng trống mà đồ án hướng tới lấp đầy: không chỉ xây dựng một mô hình multimodal có chỉ số AUC cao, mà tập trung chứng minh (hoặc bác bỏ, một cách trung thực) giá trị gia tăng của multimodal fusion đúng trên nhóm bệnh nhân khó nhất về mặt lâm sàng.

²He L, Yang Z, Wang Y, et al. A deep learning algorithm to identify carotid plaques and assess their stability. *Frontiers in Artificial Intelligence*, 2024;7:1321884.

³Gao Y, Wang H, Zhou D, et al. A clinically deployable deep learning model for automated stroke risk stratification in carotid atherosclerotic plaque. *Frontiers in Medicine*, 2026;13:1764968.

⁴Ren BW, Zhou R, Cheng X, Ding M, Chiu B. Cascaded Deep Learning-Based Model for Classification and Segmentation of Plaques from Carotid Ultrasound Images. *Bioengineering*, 2026;13(2):190.

Chương 3

PHƯƠNG PHÁP LUẬN

3.1 Tổng quan quy trình thực hiện (Pipeline)

Toàn bộ quy trình thực nghiệm của đề án được tổ chức thành 7 giai đoạn (phase) kế tiếp nhau, minh hoạ ở Bảng 3.1. Cách chia giai đoạn này cho phép kiểm chứng độc lập từng thành phần trước khi ghép vào mô hình đầy đủ, đồng thời tạo điều kiện phát hiện sớm các vấn đề về dữ liệu/huấn luyện (như trình bày ở Chương 5).

Bảng 3.1: Tổng quan 7 giai đoạn của pipeline thực nghiệm

Phase	Tên giai đoạn	Nội dung chính
1	EDA & Hiểu dữ liệu	Khảo sát phân bố, xác thực định nghĩa discordant (33 ca), chuẩn hoá nhân echogenicity
2	Data pipeline	Xây dựng <code>CarotidDataset</code> , chiến lược mã hoá/scale, augmentation ảnh
3	Baseline models	ESC/EAS Rule, RF/XGBoost/MLP (tabular), CNN-only (ảnh)
4	Kiến trúc Fusion	Image Branch + Tabular Branch + Fusion Layer + 3 output heads
5	Huấn luyện	3-stage fine-tuning, multi-task loss, 5-fold cross-validation
6	Đánh giá & Ablation	So sánh 7 mô hình, ablation 5 biến thể, phân tích subgroup discordant
7	Trả lời Research Questions	Tổng hợp bằng chứng trả lời 4 câu hỏi nghiên cứu (RQ1–RQ4)

3.2 Mô tả dữ liệu

3.2.1 Nguồn dữ liệu và cỡ mẫu

Bộ dữ liệu gồm **300 bệnh nhân**, trong đó 205 thuộc nhóm control (không có mảng bám, `Plaque_present = 0`) và 95 thuộc nhóm case (có mảng bám, `Plaque_present = 1`) – tỷ lệ mất cân bằng lớp xấp xỉ 2,16:1. Mỗi bệnh nhân có:

- **9 biến lâm sàng dạng bảng:** `Age`, `Sex`, `Lp(a)_mg_dL`, `ApoB_mg_dL`, `LDL_C_mg_dL`, `Triglyceride_mg_dL`, `Total_Cholesterol_mg_dL`, `Non_HDL_mg_dL`, `IMT_mm` (độ dày lớp nội trung mạc). Biến `Baseline_Risk_Score` bị loại khỏi tập đặc trưng vì đây là biến phái sinh (derived) trực tiếp từ nhân, có nguy cơ gây rò rỉ dữ liệu (data leakage) nếu đưa vào mô hình.

- **Ảnh siêu âm:** bệnh nhân control có 1 ảnh IMT; bệnh nhân case có 5 ảnh (1 ảnh IMT + 4 ảnh mặt cắt ngang động mạch cảnh chung trái/phải, mỗi bên 2 ảnh – CCA_L1, CCA_L2, CCA_R1, CCA_R2).

3.2.2 Nhãn đa nhiệm (multi-task labels)

Mô hình Fusion được thiết kế để dự đoán đồng thời 3 đầu ra, tương ứng 3 bài toán lâm sàng:

1. **Head 1 – Plaque Detection** (nhị phân): có/không có mảng bám.
2. **Head 2 – Echogenicity** (4 lớp): None (không có mảng bám, $n = 205$), Low ($n = 28$), Intermediate ($n = 40$), High ($n = 27$) – phản ánh độ hồi âm của mảng bám, chỉ số quan trọng đánh giá độ ổn định/nguy cơ vỡ mảng bám (mảng bám echogenicity thấp thường liên quan đến nguy cơ vỡ cao hơn – “vulnerable plaque”).
3. **Head 3 – Reclassify** (nhị phân): dự đoán bệnh nhân có cần tái phân tầng nguy cơ theo tiêu chí ESC/EAS 2025 hay không (dựa trên sự hiện diện của risk modifier khi LDL-C đã đạt mục tiêu).


3.2.3 Định nghĩa nhóm Discordant

Theo đúng tiêu chí Box 1 và Table 3–4 của guideline ESC/EAS 2025, một bệnh nhân được gán nhãn `is_discordant = True` khi **đồng thời**: (i) chỉ số LDL-C đã đạt mục tiêu điều trị theo mức nguy cơ nền (`at_ldl_goal = True`), và (ii) tồn tại ít nhất một risk modifier không được phản ánh bởi LDL-C – cụ thể là $Lp(a) > 50$ mg/dL (`lpa_elevated = True`) hoặc có mảng bám thực sự trên ảnh (`has_plaque = True`). Áp dụng định nghĩa này lên 300 bệnh nhân xác định đúng **33 trường hợp discordant** – phù hợp với kỳ vọng thiết kế của bộ dữ liệu, được xác thực chéo (assertion check) xuyên suốt cả 3 giai đoạn EDA, Baseline và Fusion.

3.3 Kiến trúc mô hình Multimodal Fusion

3.3.1 Tổng quan kiến trúc

Kiến trúc MultimodalFusionModel gồm 4 thành phần chính, minh hoạ ở Hình 3.1: (1) **Image Branch** dựa trên ResNet-50; (2) **Tabular Branch** dựa trên MLP 3 lớp; (3) **Fusion Layer** (Concatenation hoặc Cross-Attention, có thể hoán đổi qua tham số `fusion_type`); và (4) **3 Output Heads** multi-task chia sẻ chung một joint embedding 64 chiều.



Hình 3.1: Kiến trúc mô hình Multimodal Fusion: Image Branch (ResNet-50) + Tabular Branch (MLP) $\rightarrow$ Fusion Layer (Concat / Cross-Attention) $\rightarrow$ 3 output heads đa nhiệm

3.3.2 Image Branch

Image Branch (CNNBranch) sử dụng backbone ResNet-50 được khởi tạo trọng số pretrained trên ImageNet (ResNet50_Weights). Lớp fully-connected cuối cùng của ResNet-50 gốc được thay bằng Identity, giữ nguyên đặc trưng Global Average Pooling 2048 chiều. Một lớp **projection** (Linear 2048 $\rightarrow$ 128 + BatchNorm + ReLU + Dropout 0.3) được thêm vào – đây là điểm cải tiến so với thiết kế ban đầu, nhằm tránh việc embedding ảnh 2048 chiều “lấn át” embedding lâm sàng chỉ 64 chiều khi ghép nối (concat fusion). Vì mỗi bệnh nhân có số lượng ảnh khác nhau (1 hoặc 5 ảnh), toàn bộ ảnh trong một batch được ghép phẳng (torch.cat) rồi xử lý cùng lúc qua ResNet-50, sau đó **mean-pool** embedding theo đúng ranh giới từng bệnh nhân (dựa trên vector n_images lưu số ảnh của mỗi ca) để thu được 1 vector embedding 128 chiều đại diện cho mỗi bệnh nhân, bất kể có 1 hay 5 ảnh đầu vào.

Quá trình fine-tuning backbone tuân theo chiến lược **3 giai đoạn** (đồng nhất giữa CNN-only baseline và

Fusion model, xem Mục 3.6):

1. **Giai đoạn 1** (5 epoch): đóng băng toàn bộ backbone, chỉ huấn luyện các lớp mới (projection, fusion, heads).
2. **Giai đoạn 2** (15 epoch): mở khoá layer4 (block cuối của ResNet-50).
3. **Giai đoạn 3** (10 epoch): mở khoá toàn bộ backbone, giảm learning rate xuống 1/10.

3.3.3 Tabular Branch

Tabular Branch (MLPBranch) là một MLP 3 lớp ẩn đơn giản: $9 \rightarrow 64 \rightarrow 128 \rightarrow 64$, mỗi lớp gồm Linear + BatchNorm1d + ReLU (lớp thứ hai có thêm Dropout 0.2), tạo ra clinical embedding 64 chiều. Dữ liệu 9 biến đầu vào được chuẩn hoá bằng StandardScaler **fit riêng trên từng fold huấn luyện** để tránh rò rỉ thông tin từ tập validation.

3.3.4 Fusion Layer – so sánh 2 cơ chế

Đồ án triển khai và so sánh trực tiếp 2 cơ chế fusion, có thể hoán đổi qua tham số `fusion_type`:

Concatenation Fusion (mặc định). Ghép nối trực tiếp $[z_{img} \oplus z_{cli}] \in \mathbb{R}^{192}$, sau đó qua 2 lớp Linear ($192 \rightarrow 128 \rightarrow 64$), mỗi lớp có BatchNorm + ReLU + Dropout, thu được joint embedding 64 chiều.

Cross-Attention Fusion (RQ4). Ảnh đóng vai trò *Query*, dữ liệu lâm sàng đóng vai trò *Key/Value*. Cả 2 embedding được chiếu tuyến tính về cùng không gian $d_{model} = 128$, xem mỗi embedding là một sequence độ dài 1 để đưa vào `nn.MultiheadAttention` (4 head), sau đó qua residual connection + LayerNorm + feed-forward network (GELU) + LayerNorm, cuối cùng chiếu về 64 chiều – giữ đúng signature đầu ra để có thể hoán đổi trực tiếp với Concatenation Fusion trong cùng một kiến trúc tổng thể.

3.3.5 Output Heads đa nhiệm

3 output heads đều là các lớp Linear đơn giản nhận chung joint embedding 64 chiều làm đầu vào: Head 1 (Linear $64 \rightarrow 2$), Head 2 (Linear $64 \rightarrow 4$), Head 3 (Linear $64 \rightarrow 1$). Hàm mất mát tổng hợp là tổ hợp tuyến tính có trọng số của 3 nhiệm vụ:

$$\mathcal{L} = \lambda_{plaque} \cdot \mathcal{L}_{CE}^{plaque} + \lambda_{echo} \cdot \mathcal{L}_{CE}^{echo} + \lambda_{reclass} \cdot \mathcal{L}_{BCE}^{reclass}$$

với $\lambda_{plaque} = 1,0$, $\lambda_{echo} = 0,5$, $\lambda_{reclass} = 0,3$ – phản ánh mức độ ưu tiên: phát hiện mảng bám (nhiệm vụ chính) được đánh trọng số cao nhất. Cả 2 nhiệm vụ phân loại (Head 1, Head 2) đều dùng **Weighted Cross-Entropy** với trọng số lớp tính theo `compute_class_weight('balanced', ...)` nhằm xử lý mất cân bằng lớp (2,16:1 cho Head 1; 205:28:40:27 cho Head 2).

3.4 Các mô hình Baseline

Để có cơ sở đối chiếu công bằng cho mô hình Fusion, đồ án xây dựng 5 baseline, kế thừa trực tiếp cách tiếp cận của các công trình liên quan (Chương 2):

Bảng 3.2: 5 mô hình baseline và công trình tham chiếu

#	Mô hình	Phương thức	Tham chiếu
1	ESC/EAS 2025 Rule	Tabular (rule-based)	Mach và cộng sự (2025) – guideline
2	Random Forest / XGBoost / MLP	Tabular (ML cổ điển)	Vu và cộng sự (2025)
3	CNN-only (ResNet-50)	Ảnh	Gao và cộng sự (2026); He và cộng sự (2024)

ESC/EAS Rule: baseline luật lâm sàng thuần túy, không dùng deep learning – dự đoán dương tính khi $LDL-C \geq$ ngưỡng mục tiêu theo mức nguy cơ nền *hoặc* $Lp(a) > 50$ mg/dL. Đây là benchmark đại diện cho “thực hành hiện tại” (status quo), không sử dụng thông tin `Plaque_present` để dự đoán (vì đây chính là biến mục tiêu cần dự đoán).

Random Forest / XGBoost / MLP (sklearn): 3 mô hình học máy cổ điển huấn luyện trên cùng 9 đặc trưng tabular, đánh giá bằng stratified 5-fold CV. Riêng MLP (sklearn) đóng vai trò “phiên bản đơn giản” để đối chiếu với Tabular Branch của Fusion model (kiến trúc tương tự nhưng nhỏ hơn: 64-128-64).

CNN-only: kiến trúc giống hệt Image Branch của Fusion model (ResNet-50 + projection 128 + head phân loại 2 lớp), huấn luyện độc lập chỉ trên ảnh, không có thông tin lâm sàng – dùng để đo lường chính xác đóng góp riêng của nhánh ảnh, so sánh trực tiếp với hiệu năng của Fusion model đầy đủ.

3.5 Chiến lược huấn luyện và đánh giá

3.5.1 Cấu hình huấn luyện

Bảng 3.3: Siêu tham số huấn luyện Fusion model

Tham số	Giá trị
Optimizer	AdamW (weight decay 10^{-4})
Learning rate (backbone / lớp mới)	10^{-5} / 10^{-4}
Batch size	16
Kích thước ảnh đầu vào	224×224
Gradient clipping	1.0
Số epoch (3 giai đoạn)	5 / 15 / 10
Augmentation (train)	Random horizontal flip, rotation $\pm 10^\circ$, affine translate 5%, Gaussian blur, color jitter
Seed	42

3.5.2 Chiến lược cross-validation

Các mô hình tabular (RF/XGBoost/MLP) và CNN-only được đánh giá bằng **Stratified 5-fold Cross-Validation** theo nhãn `Plaque_present`, đảm bảo tỷ lệ case/control đồng đều giữa các fold. Riêng StandardScaler (cho MLP, Fusion Tabular Branch) được fit lại độc lập trên từng fold huấn luyện để tránh rò rỉ thông tin thống kê từ tập validation sang tập huấn luyện. Ablation study (Mục 3.7) sử dụng cấu hình đơn giản hơn – một lần chia stratified 70/15/15 (train/val/test) – do giới hạn thời gian tính toán khi cần huấn luyện nhiều biến thể kiến trúc.

3.5.3 Bộ chỉ số đánh giá

Ngoài các chỉ số phân loại tiêu chuẩn (AUC-ROC, F1-score, Sensitivity, Specificity), đồ án định nghĩa thêm 2 chỉ số **đặc thù cho bài toán discordant** – đóng vai trò trung tâm trong việc đánh giá giá trị lâm sàng thực sự của mô

hình:

- **Sens@discordant**: độ nhạy (sensitivity) tính riêng trên tập con 33 bệnh nhân discordant – đo lường khả năng mô hình phát hiện đúng các trường hợp có mảng bám/Lp(a) cao mà LDL-C đơn thuần không phản ánh được.
- **NPV@discordant**: giá trị dự đoán âm tính (negative predictive value) tính riêng trên tập con discordant – đo lường độ tin cậy khi mô hình dự đoán âm tính trên nhóm bệnh nhân vốn dễ gây nhầm lẫn này.

3.6 Thiết kế Ablation Study

Để đánh giá đóng góp riêng của từng thành phần kiến trúc, đồ án huấn luyện 5 biến thể trên cùng một lần chia 70/15/15 (Bảng 3.4):

Bảng 3.4: 5 biến thể Ablation Study

Biến thể	Thay đổi so với Full Fusion
Full	Kiến trúc đầy đủ (baseline cho ablation)
w/o Lp(a)	Zero-out đặc trưng Lp(a)_mg_dL trước khi đưa vào Tabular Branch
w/o ApoB	Zero-out đặc trưng ApoB_mg_dL
w/o IMT_mm	Zero-out đặc trưng IMT_mm
w/o CNN projection	Bỏ lớp projection 2048 → 128, dùng thẳng embedding ảnh 2048 chiều

Việc “zero-out” (gán giá trị 0 sau khi đã chuẩn hoá) thay vì loại bỏ hẳn cột đặc trưng cho phép giữ nguyên kiến trúc mạng (không đổi số chiều đầu vào), cô lập chính xác ảnh hưởng của riêng biến số đó lên hiệu năng mô hình.

3.7 Môi trường thực nghiệm

Toàn bộ pipeline được cài đặt bằng Python 3.12, PyTorch (Image/Tabular Branch, Fusion) và scikit-learn/XGBoost (baseline tabular), chạy trên Google Colab với GPU T4. Mã nguồn được tổ chức thành các notebook độc lập theo từng phase (01_eda.ipynb, 02_baseline.ipynb, 03_fusion.ipynb), đồng bộ qua Google Drive để tái sử dụng dữ liệu đã annotate và checkpoint mô hình giữa các phiên làm việc.

Chương 4

THỰC NGHIỆM VÀ KẾT QUẢ


4.1 Khảo sát dữ liệu (EDA)

4.1.1 Phân bố Lp(a) theo guideline ESC/EAS 2025

Bảng 4.1 trình bày tỷ lệ có mảng bám theo từng mức phân tầng Lp(a) (Figure 3 của guideline ESC/EAS 2025). Kết quả cho thấy một **gradient sinh học rõ ràng và nhất quán**: tỷ lệ có mảng bám tăng dần đều theo mức Lp(a), từ 28,4% (tier normal) lên 37,8% (tier elevated) – đúng như kỳ vọng về mặt sinh lý bệnh học, và là bằng chứng gián tiếp cho thấy dữ liệu tabular trong bộ dữ liệu được xây dựng có tính nhất quán sinh học hợp lý.


Bảng 4.1: Tỷ lệ có mảng bám theo mức phân tầng Lp(a)

Lp(a) tier	Control	Case	Tổng	Tỷ lệ có mảng bám (%)
Normal (<30 mg/dL)	121	48	169	28,4
Slight (30–50 mg/dL)	56	30	86	34,9
Elevated (>50 mg/dL)	28	17	45	37,8




Hình 4.1: Tỷ lệ mảng bám theo Lp(a) tier (trái) và phân bố giá trị Lp(a) theo nhóm Plaque (phải), ngưỡng elevated = 50 mg/dL

4.1.2 Phân bố nhân và mất cân bằng lớp




Hình 4.2: Phân bố nhân Plaque_present – 205 control (68,3%) / 95 case (31,7%), tỷ lệ mất cân bằng 2,16:1



Hình 4.3: Phân bố 4 lớp Plaque_echoenicity: None=205, Low=28, Intermediate=40, High=27

4.1.3 Phân bố nhóm Discordant

Kết quả xác thực nhóm discordant theo đúng định nghĩa ESC/EAS 2025 (Mục 3.2.3) cho ra đúng **33/300 (11,0%)** trường hợp – khớp hoàn toàn với kỳ vọng thiết kế của bộ dữ liệu. Hình 4.4 minh họa chi tiết 5 nhóm phân loại.




Hình 4.4: Phân nhóm bệnh nhân theo tiêu chí ESC/EAS 2025 (n_discordant = 33/300, 11,0%)

4.2 Kết quả 5 mô hình Baseline

Bảng 4.2 tổng hợp hiệu năng 5 baseline, đánh giá bằng stratified 5-fold cross-validation (riêng ESC/EAS Rule là deterministic, chạy trên toàn bộ 300 bệnh nhân).

Bảng 4.2: Hiệu năng 5 mô hình baseline (mean ± std qua 5-fold, riêng ESC/EAS Rule là giá trị đơn)


Model	AUC	F1	Sens	Spec	Sens@disc.
ESC/EAS Rule	0,523	0,462	0,768	0,278	0,154
RF (5-fold)	0,698±0,089	0,450±0,083	0,337±0,080	0,932±0,040	0,499±0,284
XGBoost (5-fold)	0,643±0,102	0,454±0,066	0,411±0,086	0,820±0,070	0,499±0,284
MLP (5-fold)	0,680±0,066	0,409±0,116	0,316±0,144	0,922±0,063	0,291±0,291
CNN-only (5-fold)	1,000±0,000	0,587±0,151	1,000±0,000	0,278±0,341	1,000±0,000



Hình 4.5: So sánh AUC (trái) và Sens@discordant (phải) giữa 4 baseline tabular/rule

Nhận xét chính: ESC/EAS Rule – baseline đại diện cho thực hành lâm sàng hiện tại – chỉ đạt AUC 0,523 (gần với đoán ngẫu nhiên) và **Sens@discordant chỉ 0,154**, tức bỏ sót tới 22/26 trường hợp discordant có mảng bám thật (phân tích chi tiết ở Mục 4.4). Trong 3 mô hình tabular học máy, Random Forest cho hiệu năng tổng thể tốt nhất (AUC 0,698), phù hợp với xu hướng quan sát được ở Vu và cộng sự (2025) trên bài toán tương tự. Đáng chú ý, CNN-only đạt AUC gần như tuyệt đối (1,000±0,000) – kết quả này được phân tích kỹ và đặt trong bối cảnh phản biện ở Chương 5, vì độ đặc hiệu (Spec) chỉ đạt 0,278 với độ lệch chuẩn rất lớn (0,341), cho thấy có vấn đề về hiệu chuẩn ngưỡng dự đoán.

4.2.1 Feature Importance



Hình 4.6: Feature importance của Random Forest và XGBoost trên 9 biến tabular


IMT_mm (độ dày lớp nội trung mạc) là đặc trưng quan trọng nhất ở cả 2 mô hình (RF: 0,217; XGBoost: 0,237), phù hợp với vai trò đã được xác lập của IMT trong y văn tìm mạch như một chỉ báo sớm của xơ vữa động mạch. Age, ApoB_mg_dL và Lp(a)_mg_dL xếp tiếp theo – đáng chú ý là Lp(a) và ApoB đều nằm trong nhóm đặc trưng quan trọng hàng đầu, củng cố định hướng của guideline ESC/EAS 2025 khi đưa các chỉ số này vào diện cần đo lường hệ thống. Sex là đặc trưng ít quan trọng nhất ở cả 2 mô hình.

4.3 Kết quả mô hình Fusion

Bảng 4.3 tổng hợp kết quả trên toàn bộ 7 mô hình (OOF predictions gộp toàn bộ 300 bệnh nhân).

Bảng 4.3: So sánh toàn diện 7 mô hình (OOF predictions, n = 300)

Model	AUC	F1	Sens	Spec	Sens@disc.
ESC/EAS Rule	0,523	0,462	0,768	0,278	0,154
RF	0,690	0,454	0,337	0,932	0,423
XGBoost	0,640	0,456	0,411	0,820	0,423
MLP	0,673	0,426	0,316	0,922	0,308
CNN-only	0,976	0,562	1,000	0,278	1,000
Fusion Concat	0,9996	0,918	1,000	0,917	1,000
Fusion CrossAttn	0,9998	0,742	1,000	0,678	1,000



Hình 4.7: So sánh AUC-ROC (trái) và Sensitivity trên nhóm discordant (phải) – toàn bộ 7 mô hình

Cả 2 biến thể Fusion đều vượt trội mọi baseline về AUC. Tuy nhiên, một quan sát quan trọng là **F1-score của Fusion Concat (0,918) cao hơn đáng kể so với Fusion CrossAttn (0,742)**, dù cả hai có AUC gần như bằng nhau – gợi ý rằng dù về khả năng *xếp hạng* (ranking, đo bằng AUC) hai biến thể tương đương, hiệu năng tại *ngưỡng quyết định* 0,5 (đo bằng F1, Spec) lại khác biệt rõ rệt, với Concat cho quyết định phân loại cân bằng và đáng tin cậy hơn (Spec 0,917 so với 0,678 của CrossAttn). Điểm này được phân tích sâu hơn ở Mục 4.5 khi trả lời RQ4.

4.4 Ablation Study

Bảng 4.4 trình bày kết quả 5 biến thể ablation, huấn luyện trên cùng một lần chia 70/15/15 (tập validation của lần chia này chỉ chứa 3/33 trường hợp discordant, do đó các chỉ số Sens@discordant/NPV@discordant ở bảng này mang tính tham khảo, độ tin cậy thấp hơn nhiều so với kết quả 5-fold ở Mục 4.2–4.3).

Bảng 4.4: Kết quả Ablation Study (70/15/15 split, n_discordant trong tập val = 3)

Biến thể	AUC	F1	Sens	Spec	Sens@disc.
Full	1,000	1,000	1,000	1,000	1,000
w/o Lp(a)	1,000	1,000	1,000	1,000	1,000
w/o ApoB	1,000	1,000	1,000	1,000	1,000
w/o IMT_mm	1,000	0,824	1,000	0,806	1,000
w/o CNN projection	1,000	0,933	1,000	0,935	1,000

Nhận xét quan trọng: 3 biến thể đầu tiên (Full, w/o Lp(a), w/o ApoB) cho kết quả **giống hệt nhau tuyệt đối** ở mọi chỉ số. Đây không phải bằng chứng cho thấy Lp(a)/ApoB không có giá trị lâm sàng – mà là dấu hiệu của hiện tượng **“ceiling effect”** (hiệu ứng trần): vì nhánh ảnh một mình đã đạt hiệu năng gần tuyệt đối (Mục 4.2), bất kỳ thay đổi nào ở nhánh tabular đều bị “che khuất” hoàn toàn, khiến thiết kế ablation hiện tại **không đủ khả năng phân giải** (resolving power) để đánh giá đúng đóng góp riêng của các biến tabular này. Ngược lại, 2 biến thể w/o IMT_mm và w/o CNN projection cho thấy sự sụt giảm rõ rệt ở F1/Spec – gợi ý rằng những thành phần này (dù không làm thay đổi AUC/khả năng xếp hạng) có ảnh hưởng thực sự đến việc hiệu chỉnh ngưỡng quyết định của mô hình. Ý nghĩa và cách khắc phục hạn chế này của thiết kế ablation được thảo luận chi tiết ở Chương 5.

4.5 Phân tích Subgroup Discordant – Trọng tâm khoa học của đề án


Đây là phần phân tích quan trọng nhất của đề án, kiểm chứng trực tiếp giá trị lâm sàng của cách tiếp cận multimodal fusion trên đúng nhóm bệnh nhân mà phương pháp truyền thống dễ đánh giá sai.

4.5.1 Khả năng phát hiện đúng (Recall) trên 26 ca discordant có mảng bám thật

Trong 33 ca discordant, có **26 ca thực sự có mảng bám** (Plaque_present = 1) – đây là những trường hợp nguy hiểm nhất vì LDL-C “bình thường” đã che giấu sự tồn tại thực sự của bệnh. Bảng 4.5 và Hình 4.8 cho thấy khả năng phát hiện của từng mô hình.

Bảng 4.5: Số ca discordant có mảng bám thật (n=26) được từng mô hình phát hiện đúng

Model	Bắt đúng	Bỏ sót	Recall
ESC/EAS Rule	4/26	22	15,4%
RF	11/26	15	42,3%
XGBoost	11/26	15	42,3%
MLP	8/26	18	30,8%
CNN-only	26/26	0	100,0%
Fusion Concat	26/26	0	100,0%
Fusion CrossAttn	26/26	0	100,0%



Hình 4.8: Recall trên 26 ca discordant có mảng bám thật – các mô hình có nhánh ảnh (CNN-only, Fusion) đạt 100%

Chỉ riêng dựa trên chỉ số Recall/Sens@discordant, cả 3 mô hình có sử dụng nhánh ảnh (CNN-only, Fusion Concat, Fusion CrossAttn) đều đạt 100%, đồng hạng – không phân biệt được liệu Fusion có mang lại giá trị gia tăng thực sự so với chỉ riêng CNN-only hay không.

4.5.2 Phát hiện quan trọng: phân tích False Positive trên nhóm “Lp(a)-only”


Để phân giải câu hỏi ở trên, đồ án phân tích thêm ở cấp độ *ca bệnh* (case-level) trên 7 trường hợp discordant thuộc nhóm discordant_lpa_only – tức bệnh nhân có Lp(a) tăng cao nhưng **không có mảng bám thật** (Plaque_present = 0). Đây là phép thử về **độ đặc hiệu** (specificity) đúng trên nhóm khó nhất: liệu mô hình có báo động giả (false positive) chỉ vì thấy Lp(a) cao, trong khi ảnh siêu âm thực tế không có mảng bám?

Bảng 4.6: Báo động giả (False Positive) trên 7 ca discordant thuộc nhóm Lp(a)-only (Plaque_present = 0)

Model	False Positive	Tỷ lệ
ESC/EAS Rule	7/7	100%
RF	0/7	0%
XGBoost	0/7	0%
MLP	1/7	14%
CNN-only	6/7	86%
Fusion Concat	0/7	0%
Fusion CrossAttn	3/7	43%

Đây là phát hiện khoa học quan trọng nhất của đồ án. Trong khi CNN-only đơn nhánh đạt Recall tuyệt đối (26/26) trên nhóm có mảng bám thật, nó lại **báo động giả tới 6/7 (86%)** trên nhóm Lp(a)-only không có mảng bám – cho thấy CNN-only có xu hướng dự đoán dương tính tràn lan (over-triggering), không thực sự phân biệt tốt mà chỉ “may mắn” đạt độ nhạy cao. Ngược lại, **Fusion Concat đạt đồng thời cả độ nhạy tuyệt đối (26/26) lẫn độ đặc hiệu tuyệt đối (0/7 báo động giả)** trên đúng nhóm bệnh nhân khó nhất này – đây chính là **giá trị gia tăng định lượng được** của việc kết hợp thông tin lâm sàng (Lp(a) cao nhưng các chỉ số khác không đi kèm bất thường tương ứng) với thông tin hình ảnh, giúp mô hình Fusion không bị nhánh ảnh “dẫn dắt” sai. Fusion CrossAttn tuy cũng cải thiện so với CNN-only (3/7 so với 6/7) nhưng chưa đạt được độ đặc hiệu hoàn hảo như Fusion Concat.

4.6 Head 2 – Đánh giá phân loại Echogenicity (RQ2)



Hình 4.9: Confusion matrix Head 2 (Echogenicity) – Fusion Concat, F1-macro = 0,331

Head 2 (phân loại echogenicity 4 lớp) đạt F1-macro = 0,331 và Accuracy = 0,417 – thấp hơn đáng kể so với hiệu năng gần như tuyệt đối của Head 1. Phân tích chi tiết theo từng lớp cho thấy: lớp None (control, $n = 205$) đạt Precision hoàn hảo (1,00) nhưng Recall rất thấp (0,29); lớp Low ($n = 28$) mô hình **không nhận diện được bất kỳ trường hợp nào** ($F1 = 0$); lớp Intermediate và High có Recall cao (1,00 và 0,96) nhưng Precision thấp. Mô hình có xu hướng thiên vị dự đoán về phía các lớp Intermediate/High bất kể input, phản ánh khó khăn thực sự của bài toán phân loại 4 lớp mất cân bằng nghiêm trọng (205:28:40:27) khi chỉ có 95 mẫu dương tính để học phân biệt cả 3 mức độ hồi âm.

4.7 Trả lời 4 Research Questions

Notebook thực nghiệm tự động tính toán câu trả lời cho 4 RQ dựa trên so sánh số liệu thô. Tuy nhiên, dựa trên các phân tích chuyên sâu ở trên (đặc biệt Mục 4.4.2), đồ án trình bày lại 4 câu trả lời theo hướng **diễn giải có phản biện**, không chỉ trích dẫn máy móc kết quả so sánh bề mặt.

Bảng 4.7: Tổng hợp trả lời 4 Research Questions (đã hiệu chỉnh diễn giải)

RQ	Câu hỏi	Trả lời (đã diễn giải lại)
RQ1	Fusion AUC > CNN-only & MLP-only?	Đúng về mặt số học (Fusion=0,9996 > CNN-only=0,976 > MLP=0,673), nhưng chênh lệch Fusion so với CNN-only rất nhỏ (0,024) vì cả hai đã gần chạm trần AUC=1. Không nên diễn giải đây là bằng chứng mạnh cho giá trị gia tăng của Fusion – xem RQ3 để có bằng chứng thuyết phục hơn.
RQ2	Lp(a)/ApoB giúp cải thiện Echogenicity (Head 2)?	Không thể trả lời bằng thiết kế ablation hiện tại, do hiệu ứng “ceiling” (Mục 4.3) khiến việc bỏ Lp(a)/ApoB không gây thay đổi đo lường được. Cần thiết kế lại thí nghiệm (ví dụ: đánh giá riêng Head 2 khi loại bỏ hẳn nhánh ảnh) mới trả lời được câu hỏi này.
RQ3 *	Fusion giải quyết Discordance tốt hơn baseline?	CÓ, với bằng chứng mạnh hơn nhiều so với kết luận tự động của notebook. Nếu chỉ xét Sens@discordant, Fusion và CNN-only hoà nhau (1,000 = 1,000). Nhưng phân tích case-level (Mục 4.4.2) cho thấy Fusion Concat vượt trội tuyệt đối về specificity trên nhóm Lp(a)-only (0/7 báo động giả so với 6/7 của CNN-only) – đây là giá trị lâm sàng thực chất, không thể thấy được nếu chỉ nhìn chỉ số tổng hợp.
RQ4	Concat hay Cross-Attention tốt hơn?	Concat được khuyến nghị , dù Cross-Attention có AUC nhìn hơn không đáng kể (0,9998 so với 0,9996 – chênh lệch trong biên độ nhiễu thống kê). Xét toàn diện hơn: Concat có F1 cao hơn hẳn (0,918 so với 0,742), Specificity tổng thể cao hơn (0,917 so với 0,678), và đặc biệt không báo động giả trên nhóm discordant Lp(a)-only (0/7 so với 3/7 của CrossAttn) – Concat cho quyết định ổn định và đáng tin cậy hơn trong thực tế.

Chương 5

THẢO LUẬN VÀ HẠN CHẾ

Chương này trình bày trung thực các vấn đề phát hiện được trong quá trình thực nghiệm, được nhóm xem là một phần đóng góp học thuật quan trọng của đồ án – không kém giá trị so với các con số hiệu năng đạt được ở Chương 4. Việc chủ động truy vết nguyên nhân của những kết quả “đáng ngờ” (thay vì báo cáo chúng như thành công không phản biện) là minh chứng cho tư duy khoa học cần thiết khi ứng dụng deep learning vào lĩnh vực y khoa.

5.1 Vấn đề: AUC gần tuyệt đối của nhánh ảnh – điều tra nguyên nhân

5.1.1 Hiện tượng quan sát được

Như trình bày ở Mục 4.2–4.3, cả CNN-only (AUC 0,976–1,000) lẫn Fusion model (AUC $\approx$ 0,9996–0,9998) đều đạt hiệu năng gần như tuyệt đối trên bài toán phát hiện mảng bám – một kết quả bất thường đối với bài toán chẩn đoán y khoa dựa trên ảnh, vốn hiếm khi đạt AUC hoàn hảo ngay cả với dữ liệu lâm sàng thực và mô hình tối ưu. Vì vậy, nhóm đã tiến hành điều tra có hệ thống để xác định nguyên nhân, thay vì mặc nhiên báo cáo đây là một thành công.

5.1.2 Quy trình điều tra

Bước 1 – Loại trừ khả năng leakage qua `n_images`. Giả thuyết ban đầu là số lượng ảnh mỗi bệnh nhân (`n_images`: 1 cho control, 5 cho case) có thể bị mô hình “học lỏm” như một shortcut. Rà soát mã nguồn (`cnn_branch.py`) cho thấy `n_images` chỉ được dùng làm chỉ số vòng lặp để xác định ranh giới mean-pooling giữa các bệnh nhân trong batch, **không** được đưa vào bất kỳ lớp Linear hay phép tính nào ảnh hưởng trực tiếp đến giá trị embedding. Giả thuyết này bị bác bỏ.

Bước 2 – Kiểm tra optimistic bias trong model selection. Quy trình huấn luyện chọn `best_state` dựa trên AUC cao nhất *trên chính tập validation*, sau đó lại đánh giá cuối cùng trên đúng tập validation đó – một dạng thiên lệch lạc quan (optimistic bias) nhẹ, cộng hưởng với cỡ mẫu validation nhỏ (khoảng 60 bệnh nhân/fold). Đây là yếu tố góp phần, nhưng không đủ để giải thích toàn bộ mức độ AUC gần tuyệt đối quan sát được.

Bước 3 – Kiểm tra trực quan dữ liệu ảnh. Đây là bước quyết định: quan sát trực tiếp ảnh mẫu của một bệnh nhân case (P003, gồm 4 ảnh cắt ngang CCA và 1 ảnh IMT) cho thấy **4 ảnh CCA gần như giống hệt nhau**: nền xám đồng nhất, không có nhiều speckle đặc trưng của siêu âm thật, không có biến thiên giải phẫu – chỉ có một hình ellipse (bầu dục) màu xám đậm hơn, cố định vị trí gần chính giữa khung hình, biểu thị sự hiện diện của mảng bám.

5.1.3 Kết luận về nguyên nhân

Nguyên nhân cốt lõi của AUC gần tuyệt đối là **bản chất tổng hợp (synthetic) và đơn giản hoá quá mức của dữ liệu ảnh**: mảng bám được biểu diễn bằng một marker hình học cố định (ellipse), thay vì mô phỏng chân thực các đặc điểm siêu âm thực tế (texture, nhiễu speckle, biến thiên hình dạng/vị trí giải phẫu tự nhiên giữa các bệnh nhân). Với đặc trưng phân biệt rõ ràng và nhất quán như vậy, một mạng ResNet-50 pretrained (23,8 triệu tham số) hoàn toàn có thể học phân biệt gần như tuyệt đối chỉ sau vài epoch fine-tuning – **đây không phải lỗi kỹ thuật trong code**, mà là **hạn chế ở cấp độ thiết kế bộ dữ liệu ảnh**.

Hệ quả quan trọng đối với việc diễn giải kết quả: vì hạn chế này nằm ở dữ liệu ảnh, nó ảnh hưởng như nhau lên cả CNN-only và Fusion model – nhánh ảnh một mình đã đủ “giải” được bài toán phát hiện mảng bám trên bộ dữ liệu này, khiến **AUC tổng thể không còn là chỉ số phân biệt hiệu quả giữa các kiến trúc**. Đây là lý do đồ án phải chuyển trọng tâm đánh giá sang phân tích case-level trên subgroup discordant (Mục 4.4.2) – nơi mà bản chất mất cân bằng đặc thù của bài toán clinical vẫn tạo ra sự phân hoá có ý nghĩa giữa các mô hình, bất chấp nhánh ảnh dễ tách.

5.2 Vấn đề kỹ thuật đã phát hiện và khắc phục: lỗi round-trip CSV

Trong quá trình huấn luyện lại Ablation study, nhóm phát hiện lỗi `ValueError: classes should include all valid labels that can be in y` khi tính trọng số lớp cho Head 2 (Echogenicity). Truy vết nguyên nhân cho thấy: hàm chuẩn hoá dữ liệu (`annotate_dataframe`) chuyển giá trị NaN của nhóm control (không có mảng bám để đánh giá echogenicity) thành chuỗi literal `"None"`. Tuy nhiên, khi `DataFrame` này được lưu ra CSV rồi đọc lại bằng `pandas.read_csv()` ở phiên làm việc sau, **pandas mặc định coi chuỗi `"None"` là giá trị thiếu (NaN)** – nằm trong danh sách `na_values` mặc định của thư viện – khiến 205 dòng control bị âm thầm chuyển ngược từ `"None"` về NaN ngay khi đọc file.

Lỗi này không ảnh hưởng đến các baseline tabular/CNN-only (chỉ dùng nhãn `Plaque_present`), mà chỉ lộ diện ở Fusion model – nơi **duy nhất** sử dụng trực tiếp cột `Plaque_echogenicity` làm nhãn cho Head 2. Giải pháp khắc phục: gọi lại `annotate_dataframe(df)` ngay sau khi đọc CSV (hàm này có tính idempotent theo thiết kế, an toàn khi gọi lặp lại). Sự cố này minh hoạ một lớp lỗi phổ biến nhưng dễ bị bỏ qua trong các pipeline dữ liệu thực tế: hành vi ngầm định (implicit default behavior) của các thư viện phổ biến (ở đây là danh sách `na_values` mặc định của `pandas`) có thể âm thầm làm hỏng dữ liệu mà không phát sinh lỗi ngay lập tức, chỉ lộ ra khi có đoạn code khác vô tình chạm đúng vào phần dữ liệu bị ảnh hưởng.

5.3 Vấn đề hiệu chuẩn: bất ổn định ngưỡng quyết định của CNN-only

Phân tích theo từng fold của CNN-only (Bảng 5.1) cho thấy dù AUC đạt tuyệt đối 1,000 ở cả 5 fold (ranking hoàn hảo), tỷ lệ báo động giả tại ngưỡng mặc định 0,5 lại dao động cực lớn giữa các fold.

Bảng 5.1: Tính bất ổn định của ngưỡng quyết định CNN-only qua từng fold (n=41 ca âm tính/fold)

Fold	AUC	False Positive	Tỷ lệ FP
1	1,000	41/41	100%
2	1,000	41/41	100%
3	1,000	32/41	78%
4	1,000	27/41	66%
5	1,000	7/41	17%

Điều này cho thấy hàm mất mát Weighted Cross-Entropy (được thiết kế để xử lý mất cân bằng lớp 2,16:1)

đẩy xác suất dự đoán của các ca âm tính dồn sát ngưỡng 0,5 theo cách không ổn định giữa các lần huấn luyện – mô hình phân biệt đúng thứ hạng nhưng **giá trị xác suất tuyệt đối không đáng tin cậy**, và ngưỡng cố định 0,5 không phải lựa chọn phù hợp để đưa ra quyết định lâm sàng cuối cùng. Đây là hạn chế cần khắc phục bằng kỹ thuật hiệu chuẩn ngưỡng (ví dụ chỉ số Youden’s J, hoặc temperature scaling) trước khi một mô hình như vậy có thể được xem xét ứng dụng thực tế.

5.4 Hiệu ứng trần (Ceiling Effect) trong Ablation Study

Như đã trình bày ở Mục 4.3, thiết kế ablation hiện tại không thể trả lời RQ2 (đóng góp của Lp(a)/ApoB vào Head 2) do nhánh ảnh đã bão hoà hiệu năng (AUC=1,000) ngay ở biến thể Full, khiến mọi thay đổi ở nhánh tabular không tạo ra khác biệt đo lường được. Đây là một bài học phương pháp luận quan trọng: **thiết kế thí nghiệm ablation cần được xây dựng sao cho baseline không bị bão hoà (saturated) trước khi so sánh các biến thể** – nếu không, kết quả ablation sẽ luôn “phẳng” và không mang tính thông tin, bất kể biến số bị loại bỏ có thực sự quan trọng về mặt lâm sàng hay không.

5.5 So sánh với công trình liên quan – khoảng cách đến khả năng triển khai lâm sàng

Đối chiếu với Gao và cộng sự (2026) – công trình nhấn mạnh yêu cầu “clinically deployable” cho mô hình phân tầng nguy cơ đột quỵ từ ảnh mảng bám – kết quả của đồ án cho thấy khoảng cách còn khá xa giữa một mô hình đạt chỉ số cao trên dữ liệu tổng hợp và một hệ thống có thể triển khai lâm sàng thực tế:

- **Dữ liệu ảnh thực tế phức tạp hơn nhiều** so với marker hình học đơn giản trong bộ dữ liệu tổng hợp – cần kiểm chứng lại toàn bộ pipeline trên ảnh siêu âm thật (như trong He và cộng sự, 2024, sử dụng 3 860 ảnh thật với external test set) trước khi đưa ra bất kỳ kết luận nào về hiệu năng thực sự của kiến trúc Fusion.
- **Vấn đề hiệu chuẩn (Mục 5.3)** là rào cản trực tiếp cho khả năng triển khai – một hệ thống hỗ trợ quyết định lâm sàng cần ngưỡng quyết định đáng tin cậy và ổn định, không chỉ cần AUC cao.
- **Cỡ mẫu nhỏ của subgroup discordant** (33/300, trong đó chỉ 7 ca thuộc nhóm Lp(a)-only) khiến các kết luận ở Mục 4.4, dù có ý nghĩa định hướng, vẫn cần được kiểm chứng lại trên cỡ mẫu lớn hơn trước khi khái quát hoá.

5.6 Tóm tắt các hạn chế chính

1. Dữ liệu ảnh tổng hợp (synthetic) với đặc trưng hình học đơn giản làm giảm giá trị minh chứng của kiến trúc multimodal so với ảnh siêu âm lâm sàng thực.
2. Ceiling effect ở nhánh ảnh khiến ablation study không thể đánh giá đúng đóng góp của các biến tabular quan trọng (Lp(a), ApoB) – RQ2 chưa được trả lời thoả đáng.
3. CNN-only (và có thể cả Fusion, ở mức độ nhẹ hơn) có vấn đề hiệu chuẩn ngưỡng quyết định, thể hiện qua độ lệch chuẩn Specificity rất lớn giữa các fold.
4. Cỡ mẫu subgroup discordant nhỏ (33 ca, trong đó chỉ 7 ca Lp(a)-only) giới hạn độ tin cậy thống kê của các kết luận subgroup, dù xu hướng quan sát được nhất quán và có ý nghĩa lâm sàng hợp lý.
5. Đồ án phát hiện và khắc phục một lỗi kỹ thuật trong data pipeline (round-trip CSV làm hỏng nhãn Echogenicity) – minh hoạ tầm quan trọng của việc kiểm tra dữ liệu ở từng bước trong pipeline, không chỉ ở đầu vào ban đầu.

Chương 6

HƯỚNG PHÁT TRIỂN TIẾP THEO

Dựa trên các hạn chế đã phân tích ở Chương 5, đồ án đề xuất các hướng phát triển tiếp theo, ưu tiên theo mức độ cấp thiết:

6.1 Kiểm chứng lại trên dữ liệu ảnh siêu âm thật

Ưu tiên hàng đầu là thay thế bộ ảnh tổng hợp bằng ảnh siêu âm động mạch cảnh thực tế (tương tự quy mô của He và cộng sự (2024) với 3 860 ảnh từ 1 339 bệnh nhân, có external test set). Điều này sẽ cho phép đánh giá lại toàn bộ các câu hỏi nghiên cứu (RQ1–RQ4) trong điều kiện bài toán ảnh thực sự có độ khó tương xứng với ứng dụng lâm sàng, khắc phục hiện tượng ceiling effect đã ghi nhận.

6.2 Hiệu chuẩn ngưỡng quyết định (Threshold Calibration)

Áp dụng các kỹ thuật hiệu chuẩn xác suất đầu ra (Platt scaling, temperature scaling, hoặc tối ưu ngưỡng theo chỉ số Youden’s J trên tập validation riêng) để khắc phục vấn đề bất ổn định Specificity đã ghi nhận ở CNN-only. Đây là điều kiện tiên quyết trước khi một mô hình như vậy có thể được cân nhắc hỗ trợ quyết định lâm sàng.

6.3 Thiết kế lại Ablation Study

Thiết kế lại thí nghiệm ablation theo hướng cô lập rõ ràng đóng góp của nhánh tabular, ví dụ: (i) đánh giá Tabular Branch độc lập (không có nhánh ảnh) cho cả 3 head, đặc biệt Head 2 (Echogenicity); (ii) sử dụng dữ liệu ảnh thực (mục 6.1) để nhánh ảnh không còn bão hoà hiệu năng ngay từ đầu, giúp ablation có đủ “không gian” để thể hiện khác biệt khi loại bỏ Lp(a)/ApoB.

6.4 Mở rộng cỡ mẫu và kiểm định thống kê trên Subgroup Discordant

Mở rộng cỡ mẫu (đặc biệt nhóm discordant, hiện chỉ 33/300 với 7 ca Lp(a)-only) để có thể áp dụng kiểm định thống kê chính thức (ví dụ McNemar’s test giữa các mô hình trên cùng subgroup) thay vì chỉ so sánh trực quan như hiện tại, từ đó khẳng định chắc chắn hơn phát hiện về giá trị gia tăng của Fusion trong việc giảm báo động giả (Mục 4.4.2).

6.5 Tích hợp Explainable AI (XAI)

Mở rộng ứng dụng Grad-CAM (đã cài đặt ở mức prototype trong Phase 7) để trực quan hoá vùng ảnh mà nhánh CNN tập trung chú ý khi dự đoán, kết hợp với SHAP (theo cách tiếp cận của Vu và cộng sự, 2025) cho nhánh tabular – nhằm tăng tính diễn giải được (interpretability) của mô hình, yếu tố then chốt để bác sĩ lâm sàng tin tưởng và chấp nhận sử dụng công cụ hỗ trợ quyết định dựa trên AI.

6.6 Học liên tục đa trung tâm (Multi-center Validation)

Theo mô hình external validation của He và cộng sự (2024) và định hướng “clinically deployable” của Gao và cộng sự (2026), bước phát triển xa hơn là kiểm định mô hình trên dữ liệu từ nhiều cơ sở y tế khác nhau, đánh giá khả năng khái quát hoá khi đối mặt với sự khác biệt về thiết bị siêu âm, quy trình chụp, và đặc điểm dân số bệnh nhân giữa các trung tâm.

Chương 7

KẾT LUẬN

7.1 Tóm tắt đóng góp

Đồ án đã xây dựng và đánh giá toàn diện một mô hình học sâu đa phương thức cho bài toán phân tầng nguy cơ xơ vữa động mạch cảnh, dựa trên nền tảng hướng dẫn lâm sàng ESC/EAS 2025. Các đóng góp chính gồm:

1. Xây dựng thành công kiến trúc MultimodalFusionModel kết hợp Image Branch (ResNet-50), Tabular Branch (MLP), và cơ chế Fusion linh hoạt (Concatenation/Cross-Attention), giải quyết đồng thời 3 bài toán multi-task (Plaque Detection, Echogenicity, Reclassify).
2. So sánh định lượng và có hệ thống với 5 baseline đại diện cho các cách tiếp cận khác nhau (luật lâm sàng, học máy tabular, học sâu ảnh đơn nhánh).
3. Phát hiện quan trọng nhất: thông qua phân tích case-level, chứng minh được rằng giá trị gia tăng thực sự của multimodal fusion trên nhóm bệnh nhân discordant **không nằm ở độ nhạy** (nơi CNN-only đơn nhánh cũng đạt điểm tuyệt đối) mà nằm ở **độ đặc hiệu** – Fusion Concat là mô hình duy nhất không báo động giả trên bất kỳ trường hợp nào trong nhóm 7 bệnh nhân Lp(a) cao nhưng không có mảng bám thật, trong khi CNN-only đơn nhánh báo động giả tới 86% các trường hợp này.
4. Thực hiện phân tích phản biện nghiêm túc đối với các kết quả bất thường (AUC gần tuyệt đối), truy vết đến tận nguyên nhân gốc rễ (bản chất dữ liệu ảnh tổng hợp), thay vì báo cáo các con số một cách không phản biện – đồng thời phát hiện và khắc phục một lỗi kỹ thuật thực tế trong data pipeline.

7.2 Ý nghĩa thực tiễn

Kết quả của đồ án, dù còn giới hạn bởi tính chất tổng hợp của dữ liệu ảnh, đã minh chứng được **nguyên lý phương pháp luận** có giá trị: kết hợp thông tin lâm sàng dạng bảng và hình ảnh y khoa theo hướng multimodal fusion có tiềm năng giảm thiểu chính xác loại sai số mà cách tiếp cận đơn phương thức (chỉ lipid, hoặc chỉ ảnh) dễ mắc phải – cụ thể là hiện tượng báo động giả khi một nguồn thông tin đơn lẻ bị "đánh lừa" bởi các chỉ số bất thường không tương ứng với tình trạng bệnh lý thực sự. Đây là đóng góp phương pháp luận có thể áp dụng rộng hơn cho các bài toán multimodal khác trong hình ảnh y khoa, vượt ra ngoài phạm vi cụ thể của xơ vữa động mạch cảnh.

7.3 Nhận định cuối cùng

Giá trị của đồ án không chỉ nằm ở các chỉ số hiệu năng đạt được, mà còn ở quy trình khoa học được áp dụng xuyên suốt: từ việc đặt câu hỏi nghiên cứu rõ ràng (4 RQ), xây dựng baseline công bằng, đến việc **chủ động hoài nghi và**

kiểm chứng các kết quả trông có vẻ “quá tốt để là thật”. Trong bối cảnh AI y khoa ngày càng được ứng dụng rộng rãi nhưng cũng tiềm ẩn nhiều rủi ro về tính tin cậy, năng lực nhận diện và diễn giải đúng bản chất giới hạn của mô hình – thay vì chỉ tối ưu hoá con số – là kỹ năng cốt lõi mà đồ án này hướng đến rèn luyện và minh chứng.

TÀI LIỆU THAM KHẢO

1. Mach F, Koskinas KC, Roeters van Lennep JE, Tokgözoğlu L, Badimon L, Baigent C, Benn M, Binder CJ, Catapano AL, De Backer GG, Delgado V, Fabin N, Ference BA, Graham IM, Landmesser U, Laufs U, Mihaylova B, Nordestgaard BG, Richter DJ, Sabatine MS, and ESC/EAS Scientific Document Group. *2025 Focused Update of the 2019 ESC/EAS Guidelines for the management of dyslipidaemias*. European Heart Journal, 2025, ehaf190.
2. Vu T, Kokubo Y, Inoue M, Yamamoto M, Mohsen A, Martin-Morales A, Dawadi R, Inoue T, Tay JT, Yoshizaki M, Watanabe N, Kuriya Y, Matsumoto C, Arafa A, Nakao YM, Kato Y, Teramoto M, Araki M. *Machine Learning Model for Predicting Coronary Heart Disease Risk: Development and Validation Using Insights From a Japanese Population-Based Study*. JMIR Cardio, 2025;9:e68066.
3. He L, Yang Z, Wang Y, Chen W, Diao L, Wang Y, Yuan W, Li X, Zhang Y, He Y, Shen E. *A deep learning algorithm to identify carotid plaques and assess their stability*. Frontiers in Artificial Intelligence, 2024;7:1321884.
4. Gao Y, Wang H, Zhou D, Mai P, Li X, Li P, Li Y, Wang H. *A clinically deployable deep learning model for automated stroke risk stratification in carotid atherosclerotic plaque*. Frontiers in Medicine, 2026;13:1764968.
5. Ren BW, Zhou R, Cheng X, Ding M, Chiu B. *Cascaded Deep Learning-Based Model for Classification and Segmentation of Plaques from Carotid Ultrasound Images*. Bioengineering, 2026;13(2):190.